

week2

本周完成

1. 使用 **CIFAR-10 数据集**并根据 **CIFAR-10 模型**设计并运行了卷积神经网络
2. 阅读了一篇博士论文

下周计划

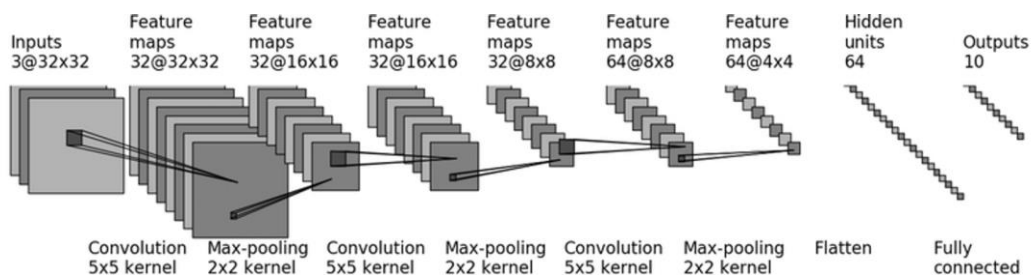
1. 学习循环神经网络与通道注意力
2. 阅读一篇论文

CIFAR-10 数据集

CIFAR-10 数据集由 10 类 32×32 的彩色图片组成，一共包含 60000 张图片，每一类包含 6000 图片。其中 50000 张图片作为训练集，10000 张图片作为测试集。

CIFAR-10 数据集被划分成了 5 个训练的 batch 和 1 个测试的 batch，每个 batch 均包含 10000 张图片。测试集 batch 的图片是从每个类别中随机挑选的 1000 张图片组成的，训练集 batch 以随机的顺序包含剩下的 50000 张图片。不过一些训练集 batch 可能出现包含某一类图片比其他类的图片数量多的情况。训练集 batch 包含来自每一类的 5000 张图片，一共 50000 张训练图片。

CIFAR-10 模型结构



网络模型代码展示

```

class G_mod(nn.Module):
    def __init__(self):
        super(G_mod, self).__init__()
        self.model1 = Sequential(
            Conv2d(in_channels=3, out_channels=32, kernel_size=5, padding=2),
            MaxPool2d(2),
            Conv2d(in_channels=32, out_channels=32, kernel_size=5, padding=2),
            MaxPool2d(2),
            Conv2d(in_channels=32, out_channels=64, kernel_size=5, padding=2),
            MaxPool2d(2),
            Flatten(),
            Linear(in_features=1024, out_features=64),
            Linear(in_features=64, out_features=10)
        )
    2 usages (2 dynamic)
    def forward(self, x):
        x = self.model1(x)
        return x

```

损失函数用交叉熵损失函数，学习率设置 0.01，优化设置梯度下降

```

for i in range(epoch):
    print("-----第{}轮训练开始-----".format(i))
    #训练
    g_mod.train()
    for data in train_dataLoader:
        imgs, targets = data
        output = g_mod(imgs)
        loss = loss_fn(output, targets)
        optim.zero_grad()
        loss.backward()
        optim.step()
        total_train_step = total_train_step + 1
        if total_train_step % 100 == 0:
            print("训练次数: {} Loss: {}".format(total_train_step, loss.item()))
            writer.add_scalar(tag="train loss", loss.item(), total_train_step)
    #验证
    total_test_loss = 0
    total_accuracy = 0
    g_mod.eval()
    with torch.no_grad():
        for data in test_dataLoader:
            imgs, targets = data
            output = g_mod(imgs)
            loss = loss_fn(output, targets)
            total_test_loss = total_test_loss + loss.item()
            accuracy = (output.argmax(1) == targets).sum()
            total_accuracy = total_accuracy + accuracy.item()

    print("整体测试集上的loss: {}".format(total_test_loss))
    print("整体测试集上的正确率: {}".format(total_accuracy/test_data_size))
    writer.add_scalar(tag="test_loss", total_test_loss, total_test_step)
    writer.add_scalar(tag="test_loss", total_accuracy/test_data_size, total_test_step)
    total_test_step = total_test_step + 1
    print("100% + %s" % (total_test_step - 1) * 100)

```

基于脑电的情绪和注意力识别及其应用研究_黄海云

摘要:

本文的主要研究方向为 BCI 领域 (脑机接口 (*brain-computer interface, BCI*)) 中的 情绪识别和注意力检测, 并对其应用进行探索研究。

1. 探究人脑处理**高兴情绪**以及**悲伤情绪**的脑模式,并开发**情感交互脑机接口系统**,本文提出了一种**情绪识别脑机接口系统**,该系统采用高兴和悲伤的情绪影片作为刺激材料,诱发被试相应的情绪反应,10 名健康被试首先测试了该情绪识别 BCI 系统的有效性,取得了 **91.5%的平均在线识别准确率**,离线分析的结果表明,高兴和悲伤情绪的大脑模式具有**差异性**,特别是在 θ (θ)频带的前额区域、 β (β)以及 γ (γ)频带的颞叶区域 (脑电波 (*Electroencephalogram, EEG*) 的波段划分),情绪识别 BCI 系统被**应用**在意识障碍患者的**情绪诱发和识别**上。参与实验的 8 位意识障碍患者之中,有 3 位患者的情绪被成功的诱发和识别。本文所提出的情绪识别 BCI 系统为意识障碍患者的临床情绪检测提供了潜在的手段。
2. 为了提升上述情绪识别 BCI 系统的性能以及研究更多不同类型情绪的脑模式,本文提出了**恐惧情绪**识别的 BCI 系统,本文**融合**了功能连接的**脑网络分析方法**和**传统频谱分析**的方法对恐惧情绪和中性情绪进行分类识别以及模式研究。结果表明,**侧重于各脑区之间信息交互的脑网络方法和传统的频谱能量激活的方法都包含有区分两类情绪状态的信息**。两种分析方法从不同的角度解析大脑处理情绪的模式,但得出的结论具有一致性。
3. 研究**耳鸣患者**的**静息态频谱特性**以及耳鸣患者和健康被试注意力的差异性,设计了**包含静息态和任务态**的注意力测试实验,采集了 16 名耳鸣患者以及同等数量健康被试的 **EEG 数据**。方法上,使用**时频分析方法**对比耳鸣患者和健康被试的频谱图,并通过**统计检验**的方法找出具有**显著性差异**的大脑区域和频带范围。**静息态实验结果表明**,耳鸣患者的频谱能量在所关注的全部频带上**都高于健康被试**,具有显著性差异的区域主要集中在 θ 和 α 频带右侧颞叶, β 以及 γ 频带的颞叶、前额和顶叶区域。**任务态实验结果显示**,耳鸣患者注意力分类准确率**明显低于健康被试**,**耳鸣可能导致了患者的注意力衰弱**。
4. 使用深度学习的方法,开发了**无需训练的、更便携的高性能注意力检测 BCI 系统**。首先使用 **Neuroscan 放大器**以及自主研发的头环设备,采集了大量被试的**注意力数据**。然后,信噪比更高的 Neuroscan 设备采集到的 EEG 数据被当作**训练集**,建立了**跨个体**的深度学习模型,并取得了**较高的识别准确率**。最后,将得到的跨个体的深度学习模型进行微调,使模型适用于头环设备。实验结果表明,用 Neuroscan 设备采集数据所建立的**深度学习模型**,能够很好的**迁移和应用**在头环设备的**注意力检测**之上。我们使用头环设备开发了**在线的注意力调控系统**,实时的对被试的注意力水平进行检测并通过屏幕上曲线动态的反馈给被试。测试结果也验证了我们的注意力 BCI 系统能够很好的**检测和反馈被试的注意力**。

简单总结

作者通过 4 个大章节分别介绍了

1. 一种在线的情绪识别 BCI 系统并将其应用于意识障碍患者的情绪诱发和识别之上。(第二章)
2. 进一步研究了恐惧情绪的 BCI 系统。(第三章)
3. 着重于基于 EEG 信号的注意力研究,并探究耳鸣患者和健康被试注意力的差异性(第四章)。
4. 使用深度学习模型训练后的结果, 搭建了实时实时的注意力调控系统 (第五章)

第二章

问题：

已有的在线情绪识别脑机接口系统识别准确率还有很大上升空间, 而且应用也还很缺乏。临床上对意识障碍的评估方法主要是**依靠行为量表**。到目前为止还没有使用 BCI 方法检测意识障碍患者情绪的研究。

创新：

提出了一种在线的情绪识别脑机接口系统 (BCI) 并成功将其应用在意识障碍患者的情绪检测上。

实验：

使用**挑选好的高兴和悲伤**的情绪影片来诱发被试的相应情绪, 并使用我们的系统进行**识别**。

材料：从中文电影或者相声节目中挑选了 140 个包含高兴或者悲伤情景的片段；然后, 每个片段都被剪切成 30 秒左右, 并且影片的声音大小都被调整到一致；所有影片进行**分类**(高兴或悲伤)以及评级(完全无感、有点触动、非常触动)。最终, 40 个被所有评分员评定为非常高兴或非常悲伤的中文影片片段被挑选出来, 其中高兴和悲伤的片段各占 20 个。

采集设备：采集脑电信号使用的是 Compumedics 公司旗下 Neuroscan 品牌的 SynAmps2 型号放大器。

实验过程：每个 trial 开始前会有 5 秒钟显示提示语, 提示接下来的播放影片是高兴或者悲伤的片段。提示语的内容是“即将播放高兴/悲伤影片, 请做好准备”。然后, 屏幕上会播放时长约 30 秒的高兴/悲伤的影片, 被试的 EEG 数据被

同步记录和处理。影片播放结束后,在线的识别结果就会反馈到屏幕上。总共包含 40 个 trial,其中前 20 个 trial 为训练阶段,后 20 个 trial 为在线测试阶段。

人员: 10 位学生作为健康对照组参加本实验, 8 位意识障碍患者参与了本次实验。

训练模型: 建立**线性核支持向量机分类器**,使用的工具箱为 LIBSVM,把高兴和悲伤情绪的特征向量标记为+1 和-1 **两类**,若预测值大于 0 则系统识别被试的情绪为高兴状态并反馈笑脸,反之则识别为悲伤状态并反馈哭脸。

结果: 验证了高兴和悲伤情绪的脑神经模式。**高兴情绪**的处理主要和左**前额脑区**相关,而**悲伤情绪**主要在**右半脑区加工处理,**我们的方法能实时的诱发和识别被试的情绪状态,并且在线的输出能够反馈给使用者并提升系统性能。

局限: 被试的数量需要进一步增加,可以考虑其他更多类型的情绪,譬如恐惧、惊讶以及厌恶等

展望: 日常生活场景下的情绪以及自我诱发的情绪识别还需要进一步的研究。扩展到日常生活场景。

第三章

问题: 连续情绪模型由于被试间的评分尺度有较大差异,存在一定的局限性。而已有的基于离散模型的情绪识别研究中,研究者们大多只关注高兴/悲伤,正性/负性情绪,**缺乏对特定情绪**,譬如恐惧情绪的研究。恐惧情绪能够更快速的激发更强烈的脑部活动,可能**更适用于**意识障碍患者的情绪检测

创新: **基于**上文建立的高兴和悲伤情绪识别脑机接口系统,融合了功能连接的脑网络方法以及传统的频谱能量的方法对两种情绪进行识别以及模式研究。

材料,采集,实验过程: 与第二章类似,对影片的恐怖度分类。

人员: 15 位健康被试(9 位男性,年龄在 22-35 岁之间,无情感障碍等精神疾病)参与本情绪识别脑电实验。

训练: 单独使用 PSD 特征以及脑网络特征 BNP 进行训练及分类,并对比其在各个子频带内的分类情况。然后,我们将两种特征融合,再进行训练和分类识别。并使用 SVM 以及贝叶斯线性判别分析进行训练和分类识别。

结果: **分类识别准确率上**。高频带的分类准确率明显的高于低频带的分类准确率;频谱能量拓扑图及脑网络连接分析上,**恐惧情绪和中性情绪在低频带的频谱能量拓扑图的模式比较相似**,也可能是导致低频带 PSD 特征分类准确率较低的原因。脑网络参数对比上,在 β 频带内,恐惧情绪的全局效率和局部效率都显著的高于中性情绪($ttest, p < 0.05$)。在 γ 频带内,恐惧情绪除了全局效率

Eglob 和局部效率 Eloc 明显高于中性情绪之外,还观察到了集群系数之间也具有显著性差异。

结论:实验结果表明,两种分析方法都具有区分恐惧情绪和中性情绪的信息,且融合后分类效果更好。此外,对频谱能量拓扑图以及脑网络连接进一步的分析发现, β 和 γ 频带在区分两种情绪中占有重要作用,颞叶、前额区域以及顶叶的脑区活动和恐惧情绪的处理息息相关。

第四章

问题:大多数已有的研究都只关注了耳鸣患者静息态的脑活动情况,任务态下的研究还十分匮乏。耳鸣对患者其他认知活动的影响尚不明确,譬如对注意力的影响。

创新:采集了长期性耳鸣患者的静息态脑电数据,使用时频分析方法对比耳鸣患者和健康被试频谱能量图的差异性,并通过假设检验找出显著性差异的大脑区域和频带区间。设计了任务态的注意力实验,对比耳鸣患者和健康被试者二者任务态的分类准确率以及注意力相关的生理指标,研究耳鸣对患者注意力的影响。

人员:16 名耳鸣患者。16 名学生无耳鸣病史以及听力损伤的健康被试作为对照组。

采集设备:Neuroscan 公司的 NuAmps 型号脑电放大器,连接 32 通道的 Quik-Cap 电极帽,信号采样率设置为 250Hz

实验过程:

静息态实验:

在安静的房间中进行,要求被试尽量的减少眨眼以及身体和头部的移动,坐姿端正,保持安静,睁眼目视前方。使用脑电放大器记录被试 5 分钟的静息态 EEG 数据。

注意力实验:

注意力实验总共包含 30 个 trial,其中进行算术运算和保持安静这两种任务 各 15 个 trial,每个 trial 持续 60 秒。每个 trial 开始前,都会有 5 秒钟显示提示语,提醒被试本 trial 的任务类型。在 60 秒的任务过程中,被试需要按照要求完成任务,任务结束时电脑屏幕会出现提示词,也会同步进行语音播报。

数据处理:参考电极标准化技术对 EEG 数据进行重参考数据进行 50Hz 的陷波滤波,设计 0.1~70Hz 的最小相位 FIR 带通滤波器,对 EEG 数据进行滤波;EEGLAB 工具箱将滤波后 EEG 数据进行独立成分分析,挑选并剔除和眼电成分相关的伪迹,对预处理完后的 EEG 数据进行短时傅里叶变换

模型训练：**分类**是指使用 EEG 数据的特征区分保持安静和进行运算这两种任务。将 30 个通道取到的特征拉伸成特征向量, 并把保持安静和进行算数运算的特征分别标记为-1 以及+1, 建立模型区分这两类任务。

结果:

双侧颞叶区域作为接收以及处理听觉相关信息的高级皮层区, 耳鸣患者在该区域的激活程度明显的高于健康被试**, 耳鸣能使听觉相关的皮层区域异常活跃**, 健康被试在 θ 以及 α 取得较高分类准确率有较大的**差异性**。目前许多研究都表明**, α 频带是和注意力相关的频带**, 而且 α 频带的频谱特征能够作为反应注意力的生理指标之一验证了注意力和 α 频带的**密切关联**。耳鸣患者在 θ 以及 α 的分类准确率都低于 δ 频带, 表明可能是耳鸣导致了患者的注意力衰弱。我们注意力集中于某件事或者专注思考时, θ / β 比值将会降低, 本研究中健康被试的结果验证了该观点。

局限: 本研究中耳鸣患者和健康被试两组被试的年龄**没有严格的匹配**, 而且对耳鸣患者实验之前用药的情况没有询问和统一。静息态的实验可以设计睁眼和闭眼两种状态, 让对比结果更全面, 并且可以**消除眨眼信号**的干扰。

结论: 耳鸣患者的频谱能量在所关注的全部频带上都高于健康被试, 具有显著性差异的区域主要集中在 θ 和 α 频带右侧颞叶, β 以及 γ 频带的颞叶、前额和顶叶区域。此外, 耳鸣患者注意力分类准确率**明显低于**健康被试, 且注意力的生理指标也和健康被试不同, 即**耳鸣可能导致了患者的注意力衰弱**。

第五章

问题: 传统的注意力评估手段主要包括医生临床诊断, 注意力评定量表以及基于行为反应的心理学评估(如 Stroop 测试)等。这些方法都不具备**实时性**, **不能应用在注意力实时检测**的环境中。

创新: 实现跨被试和设备的**注意力检测**, 并开发了**实时的注意力检测系统**。

实验设备: Neuroscan 旗下 NuAmps 型号放大器, 该设备和计算机使用 USB 以及并口线进行连接通信, 其中 USB 口传输 EEG 数据

脑电头环(华南脑控(广东)智能科技有限公司, 使用水凝胶材质的干电极, 采集受试者前额区域(Fp2)脑电信号, 采样率为 250Hz。脑电头环使用蓝牙和计算机进行连接, 将采集到的 EEG 数据传输到计算机处理或存储。

人员: 设备一进行实验的被试共有 163 人(年龄 18~25 岁之间, 其中女性 35 人)。设备二进行实验的被试共有 50 人(年龄在 19~28 岁之间, 其中女性 19 人)。

数据处理, 数据集:

我们使用一系列的滤波器组合将数据滤波并提取特征, 构建时频特征图, 再将得到的特征图作为深度学习的输入训练模型。

在 1~100Hz 频域范围内每 2Hz 设计一个零相位带通滤波器, 因此滤波后得到 50 个子频带的数据;

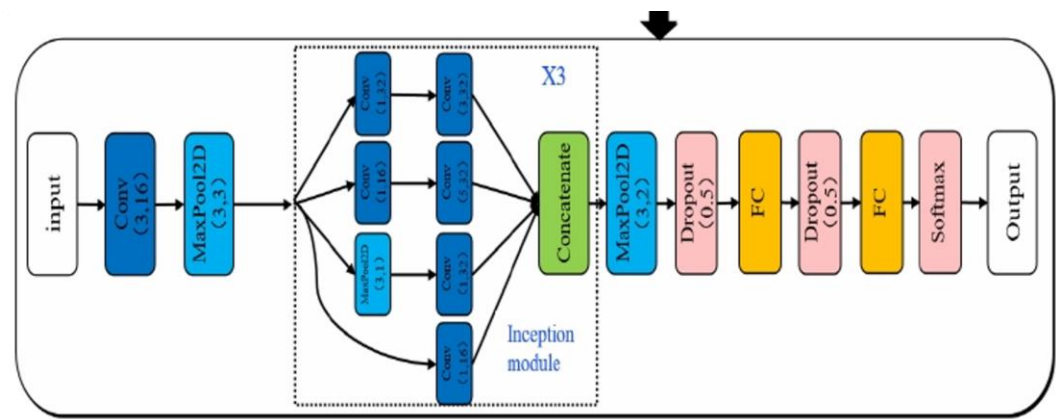
将滤波后每个 trial 的 60s 数据以 10s 的时间窗口进行无重叠的切分, 即每个 trial 切分为 6 个 epoch, 并且手动剔除幅值高于 $100\mu v$ 的包含肌电的 epoch;

每个频带内的 epoch 数据进行希尔伯特变换, 可以得到信号的幅值信息

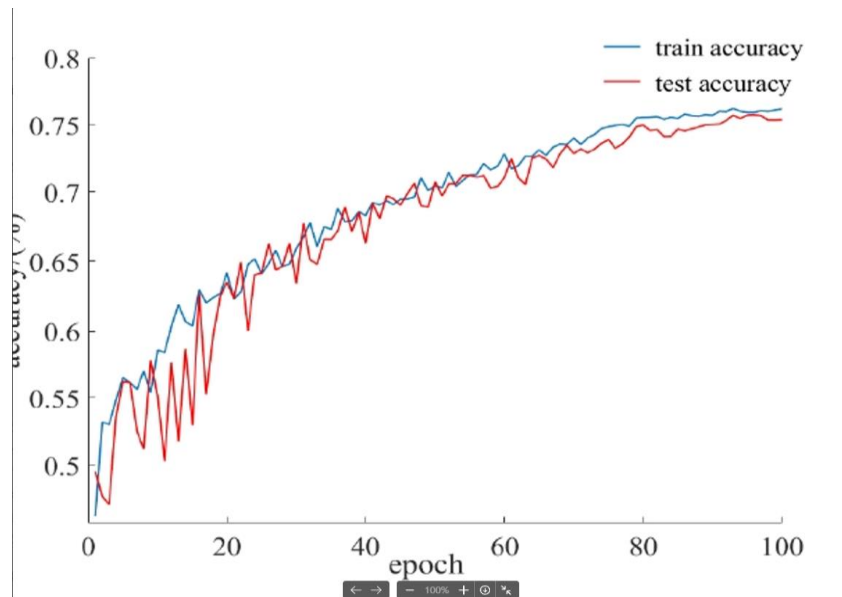
将每个 epoch 所有频带的幅值特征并接在一起, 时间维度进行重采样, 最终得到每个通道每个 epoch 数据的特征矩阵维度为 50×100 。

卷积神经网络模型训练:

基于 Inception 模块, 首先使用 3×3 的卷积以及最大池化进行初步的特性信息提取, 然后是 3 个 Inception 模块相连, 之后经过池化层以及平铺向量, 搭建了注意力识别的 Inception 深度学习网络。进行全连接, 最终经过 Softmax 计算得到类别标签。本文中激活函数均选用 ReLU。使用交叉熵损失函数。使用 AdamW 优化器, 学习速率设置为 0.001。



在所有 163 个被试上取得了 74.97%的跨被试识别准确率, 证明了我们模型以及方法的有效性。




迁移应用：

使用 Neuroscan 以及电极帽采集的注意力数据上取得了不错的跨被试识别准确率不具备便携性, 而且设备成本十分昂贵。

使用了自主研发的头环来采集注意力数据, 并开发实时的、具备实用价值的注意力识别 BCI 系统。将训练好的注意力模型进行微调, 部署在头环 BCI 系统之上, 并开发注意力检测及调控系统。

上文预处理的方法进行处理, 提取到每个 epoch 数据的时频特征矩阵, 然后输入到已有的网络模型中进行迁移学习。头环数据进行训练时, 一样采用 10 折交叉验证的方式进行训练。

但使用头环数据深度学习网络训练时, 训练准确率**只能**达到 65%左右, 而测试准确率更低且**始终难以稳定**。利用前文中已训练好的模型, 进行微调迁移学习时, 训练准确率和测试准确率**都远高于**仅用头环数据进行训练的方法, 测试准确率稳定在 75%左右。



可能存在的问题:

数据量**相对较小**: 头环使用水凝胶材质的电极, 相比于需要打胶的银/氯化银电极帽来说, 便捷性大大提高, 但可能采集到的 EEG 信号**信噪比略有降低**。

开发注意力脑机接口系统:

在注意力实时调控系统中, 我们将注意状态对应的节点的输出 score 值作为反应被试者当前注意力水平的指标, 以曲线的方式实时的显示在电脑屏幕之上, 反馈给受试者。受试者根据反馈的注意力值, 可以自己调整集中注意力或分散注意力的方式, 来完成系统的要求。系统会同步保存被试的原始 EEG 数据以及在线的注意力输出值, 方便进一步的离线计算和分析。整个系统采用 Qt 平台进行编写和搭建, 并将 Python 环境一起打包发布, 以便在线预测时, 实时的调用我们训练好的注意力深度学习模型。

结果:

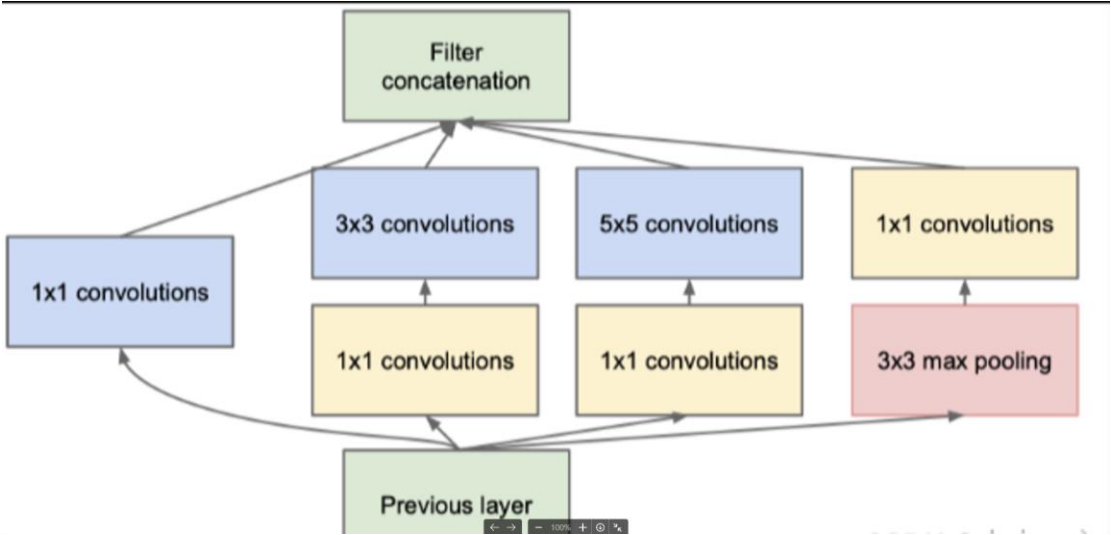
搭建了实时的注意力调控系统, 测试结果也证明了我们的系统能够很好的检测和反馈被试的注意力水平。

展望

1. 一般脑机接口系统所采集的数据量都低于 100 人/次, 而且系统的测试对象往往都是健康被试, 使用患者进行验证和测试的系统比较少。今后的研究中, 可以采集更多被试的数据, 并且更多的应用在患者身上。
2. 如何采用更加高效、更多模式的刺激方式, 也是今后的研究方向之一, 视频、音乐或者图片来进行。这种刺激往往比较单一, 而且诱发时间较长。
3. 需要用户进行较长时间的训练, 才能获得较高的识别效果, 这给 BCI 系统的应用带来了很大的阻力。今后的研究中, 将进一步探索如何缩短用户训练时长以及建立跨被试的通用模型。

额外知识补充

Inception 模块目的设计一个全新的网络结构，既能保证稀疏性，又能提高计算效率。主要思想为，卷积视觉网络中的最佳局部稀疏结构如何被现成的密集组件逼近和覆盖。下图为 Inception 模块基础。



脑机接口以及情绪识别方面的研究者主要关注**两种情绪模型**，即离散模型和连续模型

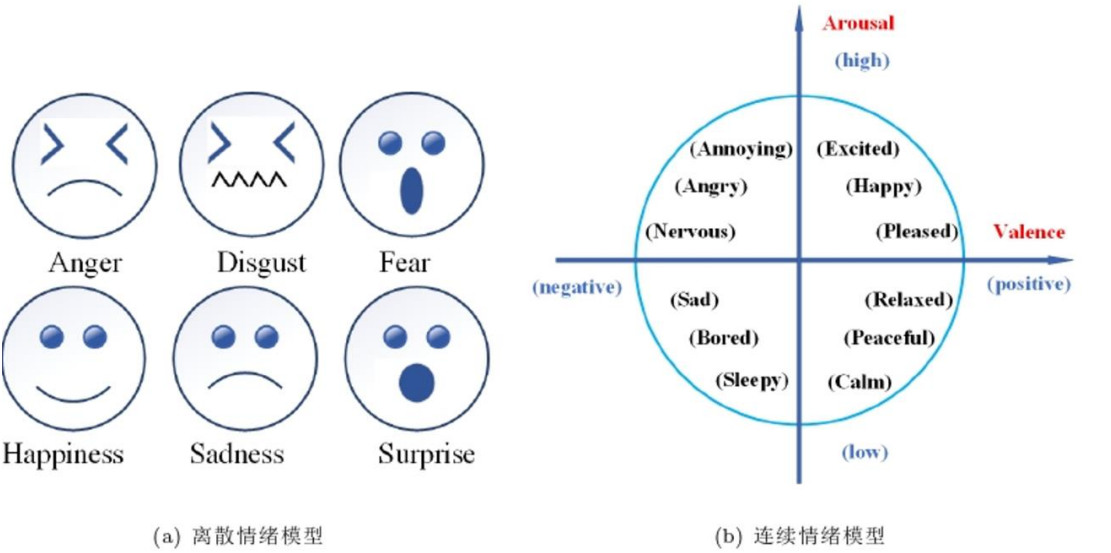


图 2-1: 不同情绪模型示意图：（a）离散情绪模型。（b）连续情绪模型

注意力和大脑认知过程的关系

